

# Introducere in programarea probabilistă

## Cursul 1

Programare și modelare probabilistă - anul III

Facultatea de Informatică, UAIC

*e-mail:* [adrian.zalinescu@uaic.ro](mailto:adrian.zalinescu@uaic.ro)

*web:* <https://sites.google.com/view/fiicoursepmp/home>

9 Octombrie, 2023

# Despre modelare probabilistă

## Motivație:

- volumele de date stocate acum sunt foarte mari (era „big data”);
- avem nevoie de instrumente capabile să:
  - ▶ să caute,
  - ▶ să vizualizeze,
  - ▶ să *modeleze* și
  - ▶ să *înțeleagă* aceste date.

## Modelare probabilistă

- Un model probabilist descrie informații pe care le-am putea observa dintr-un sistem.
- De regulă folosim teoria (matematică a) probabilităților pentru a exprima formele de incertitudine și zgomot asociate.
- Probabilitatea inversă (adică regula lui Bayes) ne permite:
  - ▶ să deducem informații necunoscute,
  - ▶ să adaptăm modelele noastre,
  - ▶ să facem predicții și
  - ▶ să învățăm din date.

## Regula lui Bayes ca bază pentru raționament probabilist

$$P(ipoteze|date) = \frac{P(date|ipoteze)P(ipoteze)}{P(date)}$$

- Regula ne învață cum să deducem (inferăm) ipoteze din date.
- Iar învățarea și predicția sunt forme de raționament deductiv (inferență).

# Modalitatea de evaluare

Nota finală va fi alcătuită din:

- **Prezență laborator 10** puncte;
  - ▶ 1 prezență = 1 punct, până la un maxim de 10p;
- **Activitate laborator 30** puncte: **teme** ce vor fi
  - ▶ anunțate la laborator;
  - ▶ predate până la termenul desemnat de profesor.
- **Examen parțial: 30** puncte
- **Examen final: 30** puncte

Condiții de promovare a disciplinei:

- **minim 8** prezențe;
- **minim 12** puncte obținute din activitatea la laborator (teme);
- **minim 25** puncte obținute din examene

## Bibliografie (selectivă):

- Osvaldo Martin, *Bayesian Analysis with Python: Introduction to statistical modeling and probabilistic programming using PyMC3 and ArviZ*, 2nd ed., 2018
  - ▶ versiune online: <https://github.com/PacktPublishing/Bayesian-Analysis-with-Python-Second-Edition>
- Cameron Davidson-Pilon, *Bayesian Methods for Hackers: Probabilistic Programming and Bayesian Inference*, 2016
  - ▶ versiune online: <https://github.com/CamDavidsonPilon/Probabilistic-Programming-and-Bayesian-Methods-for-Hackers>
- Luis Enrique Sucar, *Probabilistic Graphical Models: Principles and Applications*, Springer, 2021

Ca limbaj de programare, vom folosi Python și diverse librării ale sale:

- ▶ NumPy, SciPy, ...: oferă suport pentru distribuții probabiliste;
- ▶ Matplotlib, Seaborn, ...: suport grafic, vizualizare date;
- ▶ PyMc, pgmpy, ...: inferență (programare probabilistă).

# Plan

- 1 Despre modelare probabilistă
- 2 Despre raționament plauzibil
- 3 Elemente de teoria probabilităților
  - Formalizare
  - Variabile aleatoare
- 4 Două exemple de modele probabiliste
- 5 Programare probabilistă

## O posibilă motivație

„Știința reală a logicii este competentă în prezent numai cu lucruri certe, imposibile sau cu totul îndoielnice, pe care nu trebuie să le argumentăm (din fericire). Prin urmare, adevărata logică pentru această lume este calculul probabilităților, care ia în considerare mărimea probabilității care este sau ar trebui să fie în mintea unui om rezonabil.”

James Clerk Maxwell (1850)



# Exemplu motivator<sup>1</sup>

„Să presupunem că într-o noapte întunecată, un polițist merge pe o stradă, aparent pustie; dar dintr-o dată aude o alarmă antiefracție, se uită peste drum și vede un magazin de bijuterii cu fereastra spartă. Apoi, un domn care poartă o mască iese târându-se prin fereastra spartă, purtând o geantă care se dovedește a fi plină de bijuterii scumpe. Polițistul nu ezită deloc să decidă că acest domn este necinstit.”

---

<sup>1</sup>Probability Theory: The Logic of Science, by E. T. Jaynes

- Care este procesul de raționament prin care polițistul ajunge la această concluzie?
- Acest raționament nu este unul deductiv logic, dar are un anumit grad de validitate.
- Există și alte concluzii care se pot trage:
  - ▶ acest domn era proprietarul magazinului de bijuterii, venea acasă de la un bal mascat și nu avea cheia cu el;
  - ▶ în timp ce trecea pe lângă magazinul său, dintr-un camion care trecea s-a aruncat o piatră în fereastră, iar el doar își proteja proprietatea.
- Evidențele nu au făcut sigură necinstea domnului, dar a făcut-o extrem de plauzibilă.

## Exemplu de raționament

Un *silogism* este un tip de argument logic ce aplică raționamentul deductiv pentru a ajunge la o concluzie bazată pe două propoziții, care sunt afirmate sau presupuse a fi adevărate.

### Silogisme tari (logica Aristotelică, cu două valori)

$$\begin{array}{l} \text{dacă } A \text{ e adevărată atunci } B \text{ e adevărată} \\ A \text{ e adevărată} \\ \hline \text{deducem că } B \text{ e adevărată} \end{array}$$

și inversa

$$\begin{array}{l} \text{dacă } A \text{ e adevărată atunci } B \text{ e adevărată} \\ B \text{ e falsă} \\ \hline \text{deducem că } A \text{ e falsă} \end{array}$$

## Silogisme slabe

dacă  $A$  e adevărată atunci  $B$  e adevărată  
 $B$  e adevărată

---

deducem că  $A$  devine mai plauzibilă

dacă  $A$  e adevărată atunci  $B$  e adevărată  
 $A$  e falsă

---

deducem că  $B$  devine mai puțin plauzibilă

*Exemplu:*

$A \equiv$  Va începe să plouă până cel târziu la 10 dimineața.

$B \equiv$  Cerul va deveni noros înainte de ora 10 dimineața.

## Silogismul slab aplicat de polițist

dacă  $A$  e adevărată atunci  $B$  devine mai plauzibilă  
 $B$  e adevărată  

---

deducem că  $A$  devine mai plauzibilă

Identificați  $A$  și  $B$ .

Trebuie menționat că gradul de plauzabilitate depinde de informația apriori (experiența polițiștilor).

# Interpretări alternative ale probabilității

- Interpretarea **clasică** (Laplace): probabilitatea are de a face cu evenimente echiprobabile; dacă un anumit experiment are  $N$  rezultate posibile, atunci probabilitatea de realizare a oricărui rezultat posibil este  $1/N$ .
- Interpretarea **frecvențială**, mai utilizată în versiunea clasică a statisticii, afirmă că:  
*probabilitatea este frecvența (de unde numele) pe termen lung a producerii unui eveniment* (repetat la infinit/de un număr foarte mare de ori, în mod independent).
- Interpretarea **Bayesiană** (sau *logică, subiectivă*):  
*probabilitatea este o măsură a plauzibilității (verosimilității) sau încrederii în realizarea unui eveniment*.
- Cele două definiții ar trebui să coincidă pe exemplele în care un anumit eveniment este reproductibil la infinit.

Cele două interpretări dau naștere la principalele două abordări în probabilități și statistică:

- Interpretarea *obiectivă* (clasică, frecvențială): probabilitățile există în lumea *reală* și ele pot fi măsurate.
- Interpretarea *epistemologică* (Bayesiană): probabilitatea are de a face cu cunoașterea umană - ea măsoară încrederea.
- În domeniul inteligenței artificiale, se preferă în general ultima abordare, Bayesiană.

## Cum măsurăm gradul de plauzabilitate?

Notatii:

- $A, B, \dots$  – *propoziții*
- $\overline{A}$  sau  $\neg A$  – *negația* (nu are loc  $A$ )
- $AB$  sau  $A \wedge B$  – *conjuncția* ( $A$  și  $B$ )
- $A + B$  sau  $A \vee B$  – *disjuncția* ( $A$  sau  $B$ )
- $A \Rightarrow B$  – *implicația* ( $A$  implică  $B$ )  
echivalent cu  $\overline{A} + B$  sau cu  $A = AB$
- $A \mid B$  – *plauzibilitate condițională* ( $A$  știind  $B$ )



## Prezumții (postulate, deziderate):

- ① *Gradele de plauzibilitate sunt reprezentate de numere reale. (Divizibilitate și comparabilitate)*
- ② *Plauzibilitățile ar trebui să varieze sensibil cu evaluarea plauzibilităților din model. (Bun simț)*
- ③ *Dacă plauzibilitatea unei propoziții poate fi derivată în mai multe moduri, toate rezultatele trebuie să fie egale. (Consistență)*

Cele trei presupuneri sunt cunoscute sub numele de "Postulatele (axiomele) lui Cox".

## Teorema lui Cox:

Din cele trei postulate (și funcții adiționale utilizate pentru a le materializa), se pot deduce următoare proprietăți ale probabilităților (ca reprezentări ale gradelor de plauzabilitate):

- *adevărul* este reprezentat de  $Pr(A \mid B) = 1$  și *falsitatea* este reprezentată de  $Pr(A \mid B) = 0$ ;
- $Pr(A \mid B) + Pr(\bar{A} \mid B) = 1$ ;
- $Pr(AB|C) = Pr(A|C)Pr(B|AC) = Pr(B|C)Pr(A|BC)$ .

Cele trei proprietăți pot fi văzute ca deducții în teoria Bayesiană a probabilităților (văzută ca o extensie a calculului propozițional).

**Axiomele lui Kolmogorov** (cele pe care se bazează teoria standard a probabilităților):

$(\Omega, \mathcal{E}, P)$  – spațiu de probabilitate ( $\mathcal{E} \subseteq \mathcal{P}(\Omega)$ ,  $\sigma$ -algebră)

- $P(E) \in \mathbb{R}$ ,  $P(E) \geq 0$ ,  $\forall E \in \mathcal{E}$ ;
- $P(\Omega) = 1$ ;
- $P(\sum_{i=1}^{\infty} E_i) = \sum_{i=1}^{\infty} P(E_i)$  pentru evenimente  $E_i$ ,  $i \geq 1$ , disjuncte două câte două .

Din axiomele de mai sus se poate deduce, de exemplu, că  $A \subseteq B$  implică  $P(A) \leq P(B)$  și că  $P(\emptyset) = 0$  ( $A, B \in \mathcal{E}$ ).

## Variabilă aleatoare – Definiție

- $(\Omega, \mathcal{E}, P)$  – spațiu de probabilitate;
- $V$  – spațiu de măsură;
- O **variabilă aleatoare (v.a.)** este o funcție  $X : \Omega \rightarrow V$ ;
- Tradițional (cazul standard)  $V = \mathbb{R}$ . Dacă  $X(\Omega)$  este *finită* sau *numărabilă*, atunci  $X$  se numește *v.a. discretă*.
- **Funcția de masă de probabilitate:** (pentru v.a. discrete)

$$f_X(v) = P(X = v) = P(\{\omega \in \Omega \mid X(\omega) = v\})$$

sau **funcția de repartiție (distribuție):**

$$F_X(v) = P(X \leq v) = P(\{\omega \in \Omega \mid X(\omega) \leq v\}).$$

ne permit să facem abstracție de  $\Omega$  și să lucrăm doar cu valorile v.a. și probabilitățile acestora. Notăm  $Val(X) \equiv X(\Omega)$ .

## Variabilă aleatoare – în informatică

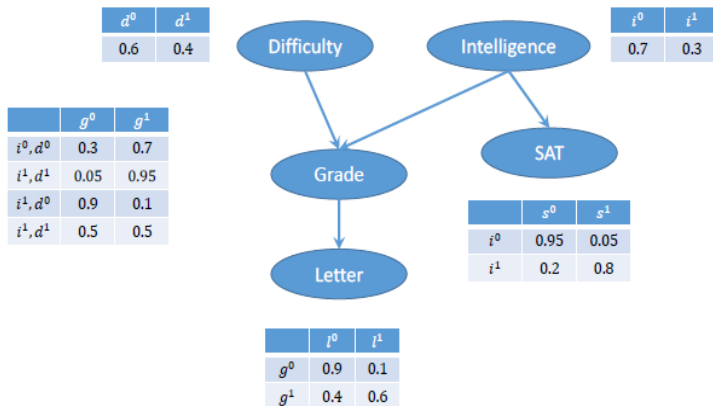
$V$  – desemnează o structură de date

În acest caz  $X : \Omega \rightarrow V$  se numește și *element aleatoriu*.

Exemple:

- valori booleene aleatoare;
- cuvinte aleatoare;
- grafuri aleatoare;
- vectori aleatori;
- funcții aleatoare;
- ....

## Modelul „Student”<sup>2</sup> - Rețea Bayesiană



<sup>2</sup>Andrew D. Gordon, Thomas A. Henzinger, Aditya V. Nori, and Sriram K. Rajamani. 2014. Probabilistic programming. In Proceedings of the Future of Software Engineering (FOSE 2014)

## Explicarea modelului

Difficulty (D), Intelligence (I), Grade (G), SAT (S), Letter (L) sunt variabile aleatoare:

$$Val(D) = \{d^0, d^1\}, P(D = d^0) = 0.6, P(D = d^1) = 0.4;$$

$$Val(I) = \{i^0, i^1\}, P(I = i^0) = 0.7, P(I = i^1) = 0.3;$$


$$Val(G) = \{g^0, g^1\}, P(G = g^0 \mid I = i^0, D = d^0) = 0.3,$$

$$P(G = g^1 \mid I = i^0, D = d^0) = 0.7, \dots;$$

$$Val(S) = \{s^0, s^1\}, P(S = s^0 \mid I = i^0) = 0.95, P(S = s^1 \mid I = i^0) = 0.05, \dots;$$

$$Val(L) = \{l^0, l^1\}, P(L = l^0 \mid G = g^0) = 0.9, P(L = l^1 \mid G = g^0) = 0.1, \dots$$

## Modelul „FSM”<sup>3</sup> - Hidden Markov Model



<sup>3</sup>Vivek Vinushanth Christopher. Markov and Hidden Markov Model. URL: <https://towardsdatascience.com/markov-and-hidden-markov-model-3eec42298d75>



## Explicarea modelului

Vectori de variabile aleatoare: **State(t)**, **Obs(s)**, unde  $t = 0, 1, 2, \dots, s = S, R$ ,

$State(0) = Start$

$$P(State(1) = S) = 0.2, P(State(1) = R) = 0.8$$

$$P(State(t+1) = S \mid State(t) = S) = 0.8$$

$$P(State(t+1) = R \mid State(t) = S) = 0.2$$

$$P(State(t+1) = S \mid State(t) = R) = 0.4$$

$$P(State(t+1) = R \mid State(t) = R) = 0.6$$

$$P(Obs(S) = H) = 0.8, P(Obs(S) = G) = 0.2$$

$$P(Obs(R) = H) = 0.4, P(Obs(R) = G) = 0.6$$

## Raționament probabilist (exemplu)

Fie  $(X_E, X_F)$  o partiționare a variabilelor aleatoare din model.

Două exemple de inferențe:

- probabilitatea marginală:

$$P(X_E = x_E) = \sum_{x_F} P(X_E = x_E, X_F = x_F);$$

- probabilitatea „maximum a posteriori” (MAP):

$$\begin{aligned} P^*(X_E = x_E) &= \max_{x_F} P(X_F = x_F \mid X_E = x_E) = \max_{x_F} \frac{P(X_E = x_E \mid X_F = x_F)P(X_F = x_F)}{P(X_E = x_E)} \\ &= \max_{x_F} P(X_E = x_E \mid X_F = x_F)P(X_F = x_F) = \max_{x_F} P(X_E = x_E, X_F = x_F). \end{aligned}$$

- probabilitatea „verosimilitate maximă” (ML):

$$\max_{x_F} P(X_E = x_E \mid X_F = x_F).$$

## Sistem de programare probabilistă

- modelul probabilist este descris de un program scris într-un limbaj de programare (DSL - limbaj specific domeniului);
- variabila aleatoare este descrisă de o variabilă program;
- sistemul pune la dispoziție un set de algoritmi de inferență probabilistă peste modelele descrise ca programe;
- interogarea constă în calculul de valori ale variabilelor program.

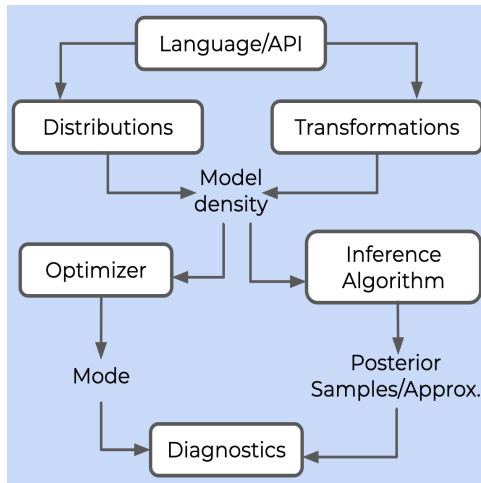


Figura: [https://danmackinlay.name/notebook/probabilistic\\_programming.html](https://danmackinlay.name/notebook/probabilistic_programming.html)

## De ce programare probabilistă?

- expresivitate  
„raționament probabilist + Turing-complete = programare probabilistă”
- raționament probabilist mai bun
- simulare mai bună (execuție + analiză)

## Provocări

- ce limbaj gazdă utilizăm pentru DSL
- cum se reprezintă o variabilă aleatoare ca un element din limbaj
- cum se construiesc modele complexe
- ce algoritmi de inferență se implementează (eficiență vs. acuratețe)
- scalabilitate: abilitatea unui sistem de a-și crește performanța dacă acel sistem este dotat cu resurse suplimentare

## Avantajele încorporării unui limbaj probabilist într-unul de programare general

- evidența poate fi descrisă în limbajul gazdă
- rezultatele date de sistem pot fi utilizate în programe
- se poate utiliza cod general în programe probabiliste
- se pot utiliza tehnici de programare generală (imperativă, funcțională, OO - object oriented) în scrierea de programe probabiliste

Listă (non-exhaustivă) de limbaje probabiliste:

[https://en.wikipedia.org/wiki/Probabilistic\\_programming](https://en.wikipedia.org/wiki/Probabilistic_programming)